

Heart Disease Prediction

Projektrapport — Pythonprogrammering med AI | ProjectEC4

1. Dataset

Ursprungligt dataset

Datasetet kommer från UCI Heart Disease (Cleveland-subset) och innehåller 303 patientposter med 13 kliniska egenskaper: ålder, kön, bröstsmärtyyp, viloblodtryck, serumkolesterol, fastande blodsocker, vilo-EKG-resultat, maximal uppnådd hjärtfrekvens, anginaprovokation, ST-depression, ST-segmentlutning, antal stora kärlfärger av fluoroskopi samt thalassemia. Målvariabeln *target* anger om patienten har hjärtsjukdom (1) eller inte (0).

Källa: UCI Machine Learning Repository — Heart Disease Dataset (Cleveland).

Utökat dataset (ProjectEC4)

För att öka modellernas generaliserbarhet kombinerades det ursprungliga datasetet med Kaggle Heart Failure Prediction Dataset (fedesoriano, 2021), som kombinerar fem hjärtsjukdomsdataset från Cleveland, Ungern, Schweiz, Long Beach VA och Stalog. Det kombinerade datasetet innehåller 918 unika poster efter borttagning av dubletter.

Kombinationsmetodik:

Det kombinerade datasetet (*heart_combined.csv*) skapas av *src/data_preparation.py*. Originalfilerna (*heart.csv* och *heart_kaggle.csv*) modifieras aldrig.

1. Kaggle-datasetet använder textetiketter för kategoriska variabler som konverteras till numeriska värden: Sex (M=1, F=0), ChestPainType (ASY=0, ATA=1, NAP=2, TA=3), RestingECG (LVH=0, Normal=1, ST=2), ExerciseAngina (N=0, Y=1), ST_Slope (Down=0, Flat=1, Up=2).
2. Kaggle-datasetet saknar två features som finns i UCI: *ca* och *thal*. Dessa imputeras med medianvärden från det ursprungliga datasetet för att bibehålla den 13-feature pipeline.
3. Fysiologiskt omöjliga nollvärden i Cholesterol (172 rader) och RestingBP (1 rad) ersätts med medianvärden.
4. Båda dataseten konkateneras och dubletter tas bort. Cleveland-subsettet ingår redan i Kaggle-datasetet, varför dedupliceringen är viktig.

2. Modellval

Tre modeller tränas och jämförs för att ge ett bredare perspektiv på problemet:

Logistic Regression — En linjärt tolkningsbar basmodell. Enkel att förstå och förklara för icke-tekniska användare. Används som baseline.

Random Forest — Ett ensemble av beslutsträd som fångar icke-linjära samband och är robust mot brus i data. Valdes som primärmodell baserat på högst noggrannhet och ROC AUC.

Decision Tree — Inkluderades för att illustrera värdet av ensemblemetoder. Ett enskilt beslutsträd tenderar att överpassa träningsdata. Trots lägre noggrannhet har det fördelen av full transparens, vilket är värdefullt i medicinska sammanhang.

Hyperparameterintervall: Random Forest tränas med 200 estimatorer (`n_estimators=200`) och Decision Tree med ett maximalt djup på 10 (`max_depth=10`) för att begränsa överpressning. Båda modellerna använder `random_state=42` för reproducerbarhet.

3. Hyperparametertuning (ProjectEC4)

I ProjectEC4 genomfördes systematisk hyperparametertuning med GridSearchCV och 5-faldig korsvalidering för att optimera modellernas prestanda på det utökade datasetet (918 rader).

Tunade parametrar:

Random Forest: `n_estimators`, `max_depth`, `min_samples_split`, `min_samples_leaf`, `max_features`

Logistic Regression: `C` (regulariseringsstyrka), `solver`, `max_iter`

Decision Tree: `max_depth`, `min_samples_split`, `min_samples_leaf`, `criterion`

Bästa parametrar valdes baserat på ROC AUC-score på valideringssettet. Slutlig utvärdering genomfördes på ett stratifierat test-set (20%, `random_state=42`).

4. Resultat

Jämförelse ProjectEC3 vs ProjectEC4:

Alla modeller utvärderades på ett stratifierat test-set (20%, `random_state=42`). Följande mätetal användes: Accuracy, F1-score, Precision, Recall och ROC AUC.

Modell	Accuracy	F1	Precision	Recall	ROC AUC
Logistic Regression	0.869	0.877	0.861	0.893	0.935
Random Forest	0.885	0.893	0.878	0.909	0.955
Decision Tree	0.754	0.771	0.750	0.793	0.754

Värden från UCI Cleveland-datasetet (303 rader) — baseline ProjectEC3.

Random Forest uppnådde bäst resultat på samtliga mätetal. I ett medicinskt sammanhang är **Recall** det mest kritiska måttet — ett missat fall av hjärtsjukdom (falskt negativt) är allvarligare än ett falskt larm. Random Forest uppnår 90.9% recall, vilket innebär att modellen korrekt identifierar nära 91% av alla sjuka patienter.

5. Etisk reflektion

Bias i datasetet

Datasetet representerar patienter där fördelningen mellan åldrar och kön är sned — majoriteten av patienterna är medelålders män. Genom att kombinera med Kaggle-datasetet ökar

representationen, men bias kan fortfarande förekomma. Innan modellen används kliniskt bör den valideras på ett mer representativt dataset.

Imputering av saknade features

Valet att imputera ca och thal med medianvärden för Kaggle-rader introducerar en känd förenkling. Dessa värden är inte uppmätta för dessa patienter — de är uppskattningar. Detta bör kommuniceras tydligt om modellen används i ett beslutsstödsystem.

Modellens tolkbarhet

Random Forest är en s.k. 'black box'-modell. Feature importance ger en övergripande bild men ersätter inte full förklarbarhet. Decision Tree erbjuder full transparens men på bekostnad av noggrannhet.

Användning i vården

Modellen är ett pedagogiskt verktyg — inte ett medicinskt diagnostikinstrument. Prediktioner ska alltid kompletteras med kliniskt omdöme och diagnostiska tester. Felaktiga prediktioner kan leda till onödig oro, överbehandling eller att en patient missas.

Projektet är tillgängligt på GitHub: github.com/TorstenssonGIT/ProjectEC4