

Heart Disease Prediction

Projektrapport — Pythonprogrammering med AI

1. Dataset

Datasetet kommer från UCI Heart Disease och innehåller 303 patientposter med 13 kliniska egenskaper: ålder, kön, bröstsmartyp, viloblodtryck, serumkolesterol, fastande blodsocker, vilo-EKG-resultat, maximal uppnadd hjartfrekvens, anginaprovokation, ST-depression, ST-segmentlutning, antal stora karlfargar av fluoroskopi samt thalassemia. Malvariabeln *target* anger om patienten har hjartsjukdom (1) eller inte (0).

Datasetet är relativt litet och härstammar från en specifik population, vilket begränsar generaliserbarheten till andra patientgrupper. Kallen är: *UCI Machine Learning Repository — Heart Disease Dataset*.

2. Modellval

Tre modeller tränades och jämfördes för att ge ett bredare perspektiv på problemet:

Logistic Regression — En linjärt tolkningsbar basmodell. Enkel att förstå och lätt att förklara för icke-tekniska användare. Används som baseline.

Random Forest — Ett ensemble av beslutsträds som fanger icke-linjära samband och är robust mot brus i data. Valdes som primärmodell baserat på högst noggrannhet och ROC AUC.

Decision Tree — Inkluderades för att illustrera värdet av ensemblemetoder. Ett enskilt beslutsträ tenderar att överpassa träningsdata. Trots lagre noggrannhet har det fördelen av full transparens — varje beslut kan följas steg för steg, vilket är värdefullt i medicinska sammanhang där förklarbarhet är viktigt.

Hyperparameterval: Random Forest tränades med 200 estimatorer (*n_estimators=200*) och Decision Tree med ett maximalt djup på 10 (*max_depth=10*) för att begränsa överpressning. Båda modellerna använder *random_state=42* för reproducerbarhet.

3. Resultat

Alla modeller utvärderades på ett stratifierat test-set (20%, *random_state=42*). Följande matetal användes: Accuracy, F1-score, Precision, Recall, ROC AUC och Confusion Matrix.

Modell	Accuracy	F1	Precision	Recall	ROC AUC
Logistic Regression	0.869	0.877	0.861	0.893	0.935
Random Forest	0.885	0.893	0.878	0.909	0.955
Decision Tree	0.754	0.771	0.750	0.793	0.754

Random Forest uppnadde bast resultat pa samtliga matetal. I ett medicinskt sammanhang ar **Recall** det mest kritiska matetet — ett missat fall av hjartsjukdom (falskt negativt) ar allvarligare an ett falskt larm. Random Forest uppnar 90.9% recall, vilket innebar att modellen korrekt identifierar nara 91% av alla sjuka patienter.

4. Etisk reflektion

Bias i datasetet

Datasetet representerar patienter dar fordelningen mellan aldrar och kon ar sned — majoriteten av patienterna ar medelaldra man. Detta innebar att modellen kan prestera samre for kvinnor, aldre patienter och andra underrepresenterade grupper. Innan modellen anvands i ett kliniskt sammanhang bor den valideras pa ett mer representativt dataset.

Modellens tolkbarhet

Random Forest ar en sa kallad 'black box'-modell — det ar svart att forklara exakt varfor ett specifikt beslut fattades. I medicinska sammanhang ar tolkbarhet viktigt for att lakare ska kunna lita pa och granska modellens rekommendationer. Feature importance ger en overgripande bild men ersatter inte full forklarbarhet. Decision Tree erbjuder full transparens men pa bekostnad av noggrannhet.

Anvandning i varden

Prediktionsmodeller for hjartsjukdom bor inte anvandas som ensam beslutsgrund i varden. Det ar viktigt att modellen kompletteras med kliniskt omdome och diagnostiska tester. Felaktiga prediktioner kan leda till onodigt oro, overbehandling eller att en patient missas. Modellen ar ett pedagogiskt verktyg — inte ett medicinskt diagnostikinstrument.