

Heart Disease Prediction Report

ProjectEC5.1 — Heart Disease Prediction Pipeline

Versionshistorik

Version	Ändringar
EC3	Grundläggande pipeline — LR, RF, DT, terminal app, Streamlit, CI/CD
EC4	Ny datakälla (Kaggle), datamängdsundersökning, hyperparametertuning, Git-tagging
EC5	XGBoost (4:e modell), SHAP-förklarbarhet, pr_checks.yml
EC5.1	Patchrelease — sektionsnumrering, 66 tester återställda, Node.js 24, relativa sökvägar

1. Dataset

Ursprungligt dataset

Datasetet kommer från UCI Heart Disease (Cleveland-subset) och innehåller 303 patientposter med 13 kliniska egenskaper: ålder, kön, bröstsmärtyyp, viloblodtryck, serumkolesterol, fastande blodsocker, vilo-EKG-resultat, maximal uppnådd hjärtfrekvens, anginaprovokation, ST-depression, ST-segmentlutning, antal stora kärlfärgar av fluoroskopi samt thalassemia. Målvariabeln **target** anger om patienten har hjärtsjukdom (1) eller inte (0).

Källa: UCI Machine Learning Repository — Heart Disease Dataset (Cleveland).

Datamängdsstrategi (EC4+)

En systematisk undersökning (*scripts/investigate_datasets.py*) visade att Cleveland-subsettet är den enda UCI-datamängden med tillförlitliga mätningar för alla 13 features. **ca** och **thal** är de två viktigaste features (~28% kombinerad importance) men saknas i 90%+ av raderna i de övriga tre UCI-dataseten (Hungarian, Switzerland, VA Long Beach). Att imputera dessa med medianvärden försämrade noggrannheten från ~88% till ~64%.

2. Modellval

Logistic Regression — Linjärt tolkningsbar basmodell. Bäst på Recall (92.9%) — kritiskt i medicinsk kontext där missade fall är allvarigare än falsklarm.

Random Forest — Ensemble av beslutsträd. Primärmodell med högst accuracy (0.902) och ROC AUC (0.955). Robust mot brus och fångar icke-linjära samband.

Decision Tree — Enskilt träd för att illustrera värdet av ensemblemetoder. Full transparens men lägre noggrannhet. Förbättrades mest av hyperparametertuning (+8.2%).

XGBoost (tillagd EC5) — Bygger träd sekventiellt där varje träd korrigerar föregåendes fel. Industristandard för tabulärdata. Matchade LR-baseline utan tuning.

3. Hyperparametertuning (EC4+)

GridSearchCV med 5-faldig korsvalidering. Scoring: **ROC AUC** — robust för obalanserade klasser.

Bästa parametrar

Modell	Parameter	Värde
Logistic Regression	C / penalty / solver	0.1 / l2 / lbfgs
Random Forest	n_estimators / max_depth / max_features	200 / 5 / sqrt
Random Forest	min_samples_split	2
Decision Tree	criterion / max_depth	gini / 3
Decision Tree	min_samples_leaf / min_samples_split	2 / 2
XGBoost	n_estimators / eval_metric	200 / logloss

Default vs tunade parametrar

Modell	Default Acc	Tuned Acc	Default AUC	Tuned AUC
Logistic Regression	0.869	0.853	0.951	0.958
Random Forest	0.902	0.902	0.955	0.958
Decision Tree	0.787	0.869 ■	0.808	0.871 ■
XGBoost	0.869	—	0.869	—

Decision Tree förbättrades mest (+8.2% accuracy, +6.3% ROC AUC). XGBoost förväntas förbättras ytterligare med tuning.

4. Resultat

Alla modeller utvärderas på ett stratifierat test-set (20%, random_state=42).

Modell	Accuracy	F1	Precision	Recall	ROC AUC
Random Forest	0.9016	0.9000	0.8438	0.9643 ■	0.9545
Logistic Regression	0.8689	0.8667	0.8125	0.9286	0.9513
XGBoost	0.8689	0.8667	0.8125	0.9286	0.9102
Decision Tree	0.7869	0.7937	0.7143	0.8929	0.8084
Decision Tree (tunad)	0.869	—	—	—	0.871

I ett medicinskt sammanhang är Recall det mest kritiska måttet — ett missat fall är allvarigare än ett falsklarm. Random Forest leder på recall (96.4%).

5. Systemets evolution — slutsatser från EC3 till EC5

EC3 → EC4: Datakvalitet slår datamängd

EC4:s ursprungliga mål var att förbättra modellerna genom att lägga till **Kaggle som ny datakälla** och öka träningsdata från 302 till 1220 rader. Under kombinationsprocessen upptäcktes att det ursprungliga datasetet innehöll **723 dubletter** — ett allvarligt dataintrångsproblem som innebar att samma patienter fanns i både tränings- och testsettet i EC3.

En systematisk undersökning visade att den intuitiva lösningen (mer data) faktiskt **försämrade noggrannheten**. Anledningen är att ca och thal — de två viktigaste features med ~28% kombinerad importance — saknas i Kaggle-datasetet.

Metod	Rader	Features	RF Accuracy	Slutsats
EC3 original (med dubletter)	1025	13	1.000	■ Dataintrång
EC3 deduplicerat	302	13	~0.885	Ärlig baseline
UCI 4 sjukhus — ta bort ca+thal	918	11	~0.672	■ Feature-förlust
Kaggle kombinerat — imputera ca+thal	1220	13	~0.643	■ Imputering otillförlitlig
Cleveland only — alla 13 features	303	13	0.902	■ Valt

303 högkvalitativa rader med alla 13 features presterar bättre än 918-1220 rader med komprometterade features. Datakvalitet slår datamängd.

EC4 → EC5: Bygger på ett validerat fundament

Med ett välmotiverat och rensat dataset lade EC5 till XGBoost som fjärde modell. XGBoost matchar Logistic Regression-baseline exakt utan tuning — bekräftar att datasettets kvalitet är solid.

SHAP-analysen validerar retroaktivt EC4:s beslut: ca och thal bekräftas av SHAP som de mest inflytelserika features.

Det evolverande systemet — sammantagen bild

Version	Vad som byggdes	Vad som lärdes	Påverkan
EC3	Pipeline, 3 modeller, terminal app	Förstärkte systemet — men data var begränsad	EC4 byggdes av mer data
EC4	Ny datakälla, undersökning, deduplikering	Mer data hjälpte inte — kvalitet slår kvantitet	EC5 fick ett rent fundament
EC5	XGBoost, SHAP-förklarbarhet	XGBoost validerar data — SHAP validerar feature-relevans	Systemet är nu robustt och byggbart

Varje version löste ett verkligt problem som upptäcktes i föregående version. Det är skillnaden mellan ett studentprojekt och ingenjörsmässigt arbete.

6. SHAP — Förklarbarhet (EC5+)

SHAP (SHapley Additive exPlanations) förklarar *varför* modellen gör en specifik prediktion. Metoden kommer från spelteori och fördelar rättvist varje features bidrag till prediktionen. Detta adresserar direkt kritiken mot black box-modeller.

Viktigaste features (Beeswarm — Random Forest)

Feature	Tolkning
thal	Låga värden driver starkt mot hjärtsjukdomsprediktion — viktigaste feature
ca	Färre stora kärl (lågt värde) ökar predikterad risk avsevärt
cp	Vissa bröstsmärtyper (högt värde) är starka sjukdomsindikatorer
thalach	Låg maxpuls är associerad med högre predikterad risk
exang	Anginautlöst av träning driver prediktioner mot sjukdom

XGBoost visar liknande feature-ranking men tenderar att producera skarpare, mer koncentrerade SHAP-värden.

7. Etisk reflektion

Bias i datasetet: Majoriteten av patienter är medelålders män. Modellen kan prestera sämre för underrepresenterade grupper. Innan klinisk användning bör modellen valideras på ett mer representativt dataset.

Datamängdsbeslut: Valet att använda Cleveland-subsettet (303 rader) är dokumenterat transparent. ca och thal är kliniskt viktiga features som inte kan imputeras reliabelt.

SHAP-förklarbarhet: Random Forest och XGBoost är black box-modeller. SHAP adresserar detta genom att förklara varje prediktion på feature-nivå — ett etiskt krav för medicinska beslutsstödsystem.

Användning i vården: Modellen är ett pedagogiskt verktyg — inte ett medicinskt diagnostikinstrument. Prediktioner ska alltid kompletteras med kliniskt omdöme och diagnostiska tester.

8. Versionshantering och CI/CD (EC5.1)

CI/CD-strategi

Workflow	Trigger	Innehåll
tests.yml	Varje push	66 tester + coverage $\geq 84\%$ + Node.js 24
pr_checks.yml	Varje pull request	Allt i tests.yml + flake8 + bandit + mypy

EC5.1 patchkorrigeringar

Problem	Åtgärd
Sektionsnumrering bruten	Sektioner 1–15 sekventiellt
pr_checks.yml saknades	Tillagd med flake8, bandit, mypy
44 tester (regression från EC4:s 66)	Återställt till 66 tester
Node.js 20 i CI/CD	Uppgraderat till Node.js 24
Hårdkodade sökvägar i main.py	Default paths använder PROJECT_ROOT
Relativa sökvägar i tester	Absoluta sökvägar via Path(__file__)

Taggar: v4.0 (EC4) → v5.0 (EC5) → v5.1 (EC5.1). Alla versioner tillgängliga under Releases på GitHub.