

Heart Disease Prediction

Projektrapport — Pythonprogrammering med AI | ProjectEC5

1. Dataset

Ursprungligt dataset

Datasetet kommer från UCI Heart Disease (Cleveland-subset) och innehåller 303 patientposter med 13 kliniska egenskaper: ålder, kön, bröstsmärttyp, viloblodtryck, serumkolesterol, fastande blodsocker, vilo-EKG-resultat, maximal uppnådd hjärtfrekvens, anginaprovokation, ST-depression, ST-segmentlutning, antal stora kärlfärgar av fluoroskopi samt thalassemia. Målvariabeln **target** anger om patienten har hjärtsjukdom (1) eller inte (0).

Källa: UCI Machine Learning Repository — Heart Disease Dataset (Cleveland).

Utökat dataset (ProjectEC5)

För att öka modellernas generaliserbarhet kombinerades det ursprungliga datasetet med Kaggle Heart Failure Prediction Dataset (fedesoriano, 2021), som kombinerar fem hjärtsjukdomsdataset från Cleveland, Ungern, Schweiz, Long Beach VA och Stalog. Det kombinerade datasetet innehåller 918 unika poster efter borttagning av dubletter.

Kombinationsmetodik: heart_combined.csv skapas av src/data_preparation.py. Originalfilerna modifieras aldrig.

- Kaggle-datasetet konverteras till numeriska värden: Sex (M=1, F=0), ChestPainType (ASY=0, ATA=1, NAP=2, TA=3), RestingECG (LVH=0, Normal=1, ST=2), ExerciseAngina (N=0, Y=1), ST_Slope (Down=0, Flat=1, Up=2).
- Saknade features ca och thal imputeras med medianvärden från UCI-datasetet.
- Fysiologiskt omöjliga nollvärden i Cholesterol (172 rader) och RestingBP (1 rad) ersätts med medianvärden.
- Båda dataseten konkateneras och dubletter tas bort.

2. Modellval

Fyra modeller tränas och jämförs:

Logistic Regression — Linjärt tolkningsbar basmodell. Används som baseline.

Random Forest — Ensemble av beslutsträd, robust mot brus. Primärmodell baserat på högst accuracy och ROC AUC.

Decision Tree — Inkluderades för att illustrera värdet av ensemblemetoder. Full transparens men lägre noggrannhet.

XGBoost — Tillagd i ProjectEC5 som fjärde modell. Bygger träd sekventiellt där varje nytt träd korrigerar felen från det föregående. Industristandard för tabulärdata — matchar Random Forest

utan extensiv tuning. Tränas med 200 estimatorer och random_state=42.

3. Hyperparametertuning (ProjectEC5)

Systematisk hyperparametertuning med GridSearchCV och 5-faldig korsvalidering. Scoring-mått: **ROC AUC** — robust för obalanserade klasser.

Bästa parametrar (GridSearchCV, cv=5)

Modell	Parameter	Värde
Logistic Regression	C / penalty / solver	0.1 / l2 / lbfgs
Random Forest	n_estimators / max_depth	200 / 5
Random Forest	max_features / min_samples_split	sqrt / 2
Decision Tree	criterion / max_depth	gini / 3
Decision Tree	min_samples_leaf / min_samples_split	2 / 2
XGBoost	n_estimators / eval_metric	200 / logloss

Jämförelse: Default vs Tunade parametrar

Modell	Default Acc	Tuned Acc	Default AUC	Tuned AUC
Logistic Regression	0.869	0.853	0.951	0.958
Random Forest	0.902	0.902	0.955	0.958
Decision Tree	0.787	0.869	0.808	0.871
XGBoost	0.869	—	0.869	—

Tuningen förbättrade framför allt **Decision Tree** avsevärt (+8.2% accuracy, +6.3% ROC AUC). Random Forest behöll sin accuracy men förbättrade ROC AUC marginellt. XGBoost matchade Logistic Regression-baseline utan tuning.

4. Resultat

Alla modeller utvärderades på ett stratifierat test-set (20%, random_state=42).

Modell	Accuracy	F1	Precision	Recall	ROC AUC
Logistic Regression	0.869	0.877	0.861	0.893	0.935
Random Forest	0.885	0.893	0.878	0.909	0.955
Decision Tree	0.754	0.771	0.750	0.793	0.754
XGBoost	0.869	—	—	—	0.869

Baseline ProjectEC3 — UCI Cleveland-datasetet (303 rader).

Random Forest uppnådde bäst resultat på samtliga mätetal. **Recall** är det mest kritiska måttet — ett missat fall av hjärtsjukdom är allvarigare än ett falskt larm. Random Forest uppnår 90.9% recall.

XGBoost matchar Logistic Regression-baseline (ROC AUC 0.869) utan hyperparameter tuning.

5. SHAP — Förklarbarhet (ProjectEC5)

SHAP (SHapley Additive exPlanations) förklarar *varför* modellen gör en specifik prediktion. SHAP kommer från spelteori och fördelar rättvist varje features bidrag till prediktionen. Detta adresserar direkt kritiken mot 'black box'-modeller — en läkare behöver förstå varför modellen förutsäger hög risk innan den agerar.

Beeswarm-plot — Random Forest

De tre mest inflytelserika features är **thal**, **ca** och **cp** — deras punkter sprider sig bredast längs x-axeln.

Feature	Tolkning
thal	Låga thal-värden driver starkt mot hjärtsjukdomsprediktion. Mest inflytelserik feature.
ca	Färre stora kärl (lågt värde) ökar predikterad risk avsevärt.
cp	Vissa bröstsmärtyper (høgt värde) är starka indikatorer på sjukdom.
thalach	Låg maximal hjärtfrekvens associeras med högre predikterad risk.
exang	Anginautlöst av träning driver prediktioner mot sjukdom.

Waterfall-plot — enskild patient

Waterfall-ploten förklarar **en enskild prediktion** — den första högriskpatienten i testsettet. Varje stapel visar hur mycket en feature drev prediktionen uppåt (röd) eller nedåt (blå). $f(x)$ = slutlig modelloutput, $E[f(x)]$ = baslinje (genomsnittlig prediktion). Detta gör prediktionen granskningsbar och förklarbar för kliniker.

Beeswarm-plot — XGBoost

XGBoost visar liknande feature-ranking som Random Forest med thal, ca och cp i topp. XGBoost tenderar att producera skarpare, mer koncentrerade SHAP-värden. Skillnader i spridning jämfört med Random Forest indikerar att modellerna viktar features olika.

6. Etisk reflektion

Bias i datasetet

Majoriteten av patienterna är medelålders män. Kaggle-datasetet ökar representationen men bias kan förekomma. Modellen bör valideras på ett mer representativt dataset innan klinisk användning.

Imputering av saknade features

Imputering av ca och thal med medianvärden introducerar en känd förenkling — värdena är uppskattningar, inte uppmätta. Detta bör kommuniceras tydligt i ett beslutsstödsystem.

Modellens tolkbarhet

Random Forest och XGBoost är 'black box'-modeller. SHAP-analys (Section 5) adresserar detta direkt genom att förklara varje prediktion på feature-nivå. Decision Tree erbjuder full transparens men på bekostnad av noggrannhet.

Användning i vården

Modellen är ett pedagogiskt verktyg — inte ett medicinskt diagnostikinstrument. Prediktioner ska alltid kompletteras med kliniskt omdöme och diagnostiska tester.

7. Versionshantering

I ProjectEC5 introducerades Git-tagging som en del av projektets arbetsflöde. En tagg sätts på main efter att alla tester är gröna och rapporten är uppdaterad.

```
git tag -a v5.0 -m "ProjectEC5 - XGBoost, SHAP explainability, combined dataset  
918 rows"
```

Taggar syns under **Releases** på GitHub och gör det enkelt att återgå till en specifik version.

CI/CD-strategi (ProjectEC5)

I ProjectEC5 delades CI/CD upp i två separata workflows:

tests.yml — Körs vid varje push. Snabb återkoppling med fullständig testsvit och täckningskontroll (min 84%).

pr_checks.yml — Körs vid varje pull request. Innehåller allt i tests.yml plus flake8 (PEP8), bandit (säkerhetsskanning) och mypy (typhintskontroll).

CI/CD-workflödet använder Node.js 24 för GitHub Actions (FORCE_JAVASCRIPT_ACTIONS_TO_NODE24: true) inför Githubs deadline den 16 juni 2026.

Projektet är tillgängligt på GitHub: github.com/TorstenssonGIT/ProjectEC5