

Heart Disease Prediction

Projektrapport — Pythonprogrammering med AI | ProjectEC4

1. Dataset

Ursprungligt dataset

Datasetet kommer från UCI Heart Disease (Cleveland-subset) och innehåller 303 patientposter med 13 kliniska egenskaper: ålder, kön, bröstsmärtyyp, viloblodtryck, serumkolesterol, fastande blodsocker, vilo-EKG-resultat, maximal uppnådd hjärtfrekvens, anginaprovokation, ST-depression, ST-segmentlutning, antal stora kärlfärger av fluoroskopi samt thalassemia. Målvariabeln *target* anger om patienten har hjärtsjukdom (1) eller inte (0).

Källa: UCI Machine Learning Repository — Heart Disease Dataset (Cleveland).

Utökat dataset (ProjectEC4)

För att öka modellernas generaliserbarhet kombinerades det ursprungliga datasetet med Kaggle Heart Failure Prediction Dataset (fedesoriano, 2021), som kombinerar fem hjärtsjukdomsdataset från Cleveland, Ungern, Schweiz, Long Beach VA och Stalog. Det kombinerade datasetet innehåller 918 unika poster efter borttagning av dubletter.

Kombinationsmetodik: `heart_combined.csv` skapas av `src/data_preparation.py`. Originalfilerna modifieras aldrig.

1. Kaggle-datasetet konverteras till numeriska värden: Sex (M=1, F=0), ChestPainType (ASY=0, ATA=1, NAP=2, TA=3), RestingECG (LVH=0, Normal=1, ST=2), ExerciseAngina (N=0, Y=1), ST_Slope (Down=0, Flat=1, Up=2).
2. Saknade features *ca* och *thal* imputeras med medianvärden från UCI-datasetet.
3. Fysiologiskt omöjliga nollvärden i Cholesterol (172 rader) och RestingBP (1 rad) ersätts med medianvärden.
4. Båda dataseten konkateneras och dubletter tas bort.

2. Modellval

Logistic Regression — Linjärt tolkningsbar basmodell. Används som baseline.

Random Forest — Ensemble av beslutsträd, robust mot brus. Primärmodell baserat på högst accuracy och ROC AUC.

Decision Tree — Inkluderades för att illustrera värdet av ensemblemetoder. Full transparens men lägre noggrannhet.

Hyperparameterval: Random Forest tränas med 200 estimatorer och Decision Tree med max djup 10. Båda använder `random_state=42` för reproducerbarhet.

3. Hyperparametertuning (ProjectEC4)

Systematisk hyperparametertuning med GridSearchCV och 5-faldig korsvalidering. Scoring-mått: **ROC AUC** — robust för obalanserade klasser.

Bästa parametrar (GridSearchCV, cv=5):

Modell	Parameter	Värde
Logistic Regression	C / penalty / solver	0.1 / l2 / lbfgs
Random Forest	n_estimators / max_depth	200 / 5
Random Forest	max_features / min_samples_split	sqrt / 2
Decision Tree	criterion / max_depth	gini / 3
Decision Tree	min_samples_leaf / min_samples_split	2 / 2

Jämförelse: Default vs Tunade parametrar:

Modell	Default Acc	Tuned Acc	Default AUC	Tuned AUC
Logistic Regression	0.869	0.853	0.951	0.958
Random Forest	0.902	0.902	0.955	0.958
Decision Tree	0.787	0.869	0.808	0.871

Tuningen förbättrade framför allt Decision Tree avsevärt (+8.2% accuracy, +6.3% ROC AUC). Random Forest behöll sin accuracy men förbättrade ROC AUC marginellt.

4. Resultat

Alla modeller utvärderades på ett stratifierat test-set (20%, random_state=42).

Modell	Accuracy	F1	Precision	Recall	ROC AUC
Logistic Regression	0.869	0.877	0.861	0.893	0.935
Random Forest	0.885	0.893	0.878	0.909	0.955
Decision Tree	0.754	0.771	0.750	0.793	0.754

Baseline ProjectEC3 — UCI Cleveland-datasetet (303 rader).

Random Forest uppnådde bäst resultat på samtliga mätetal. **Recall** är det mest kritiska måttet — ett missat fall av hjärtsjukdom är allvarigare än ett falskt larm. Random Forest uppnår 90.9% recall.

5. Etisk reflektion

Bias i datasetet

Majoriteten av patienterna är medelålders män. Kaggle-datasetet ökar representationen men bias kan förekomma. Modellen bör valideras på ett mer representativt dataset innan klinisk användning.

Imputering av saknade features

Imputering av ca och thal med medianvärden introducerar en känd förenkling — värdena är uppskattningar, inte uppmätta. Detta bör kommuniceras tydligt i ett beslutsstödsystem.

Modellens tolkbarhet

Random Forest är en 'black box'-modell. Feature importance ger en övergripande bild men ersätter inte full förklarbarhet. Decision Tree erbjuder full transparens men på bekostnad av noggrannhet.

Användning i vården

Modellen är ett pedagogiskt verktyg — inte ett medicinskt diagnostikinstrument. Prediktioner ska alltid kompletteras med kliniskt omdöme och diagnostiska tester.

6. Versionshantering

I ProjectEC4 introducerades Git-tagging som en del av projektets arbetsflöde. En tagg sätts på main efter att alla tester är gröna och rapporten är uppdaterad, och markerar en stabil release av projektet.

```
git tag -a v4.0 -m "ProjectEC4 - hyperparameter tuning, combined dataset 918 rows"
```

```
git push origin v4.0
```

Taggar syns under Releases på GitHub och gör det enkelt att återgå till en specifik version.

Projektet är tillgängligt på GitHub: github.com/TorstenssonGIT/ProjectEC4